Relatório técnico · ReliaAgents / Failure Map

LLMs, Laya e XGBoost na classificação de falhas ISO 14224

Benchmark com notas reais de manutenção e gabarito validado por especialista

---

Data: 9 de novembro de 2026

Escopo: 30 notas · 90 respostas de validação · 7 modelos

Chamadas: 680 registros · custo total US$ 1.38

Código: github.com/LHOA/Classificador-de-Falhas (pasta bench/)

Resumo executivo

Oito formas de resolver o mesmo problema: dada uma nota de manutenção em texto livre, devolver o **modo de falha**, o **mecanismo** e o **método de detecção** segundo a ISO 14224. Do lado local, o XGBoost do Failure Map e o **Laya** (encoder com cabeças de decisão). Do lado remoto, cinco LLMs de prateleira.

> **O que os números dizem.** Contra o gabarito validado pelo especialista, o **Qwen3.8 Max** lidera: **0,50** de top-1 e **0,70** de top-3 — a US$ 5,24 por mil notas. O **GPT-6 Luna** chega a 0,48 por US$ 0,27. O **XGBoost** faz 0,36 e 0,54, a custo zero e em 53 ms. Nenhum LLM inventou código em 680 chamadas.

1. Método

Amostra: 30 notas — dez por eixo — com alocação 50% classes frequentes, 30% intermediárias e 20% de cauda longa, tiradas de um histórico de 7.125 notas (6.995 após deduplicar descrições idênticas).

Gabarito: cada nota foi apresentada a um engenheiro de confiabilidade com três opções por eixo — o rótulo do dataset e dois distratores plausíveis, em ordem embaralhada — mais a saída "nenhuma destas". Ele respondeu sem ver o rótulo nem as previsões dos modelos. **A resposta dele é a referência de todas as métricas deste relatório**; o rótulo original não entrou em nenhum cálculo.

Prompt: idêntico para todos os modelos — zero-shot, taxonomia completa dos três eixos (1.766 tokens), saída JSON com top-3 por eixo, temperatura 0. A entrada é a mesma do XGBoost: `Tag`, `Description` e `Impacto`.

Baseline: XGBoost do projeto (TF-IDF de 1.500 termos + one-hot de Tag/Impacto, *n_estimators*=100). Ele viu as 30 notas no treino, então é teto otimista: re-treinado sem elas, o mesmo pipeline faz 0,33.

2. Resultado

Modelo	Top-1	Top-3	Macro-F1	US$ / 1.000 notas	Latência p50
XGBoost	**0,36**	**0,54**	**0,22**	**0,00**	**53 ms**
Laya (zero-shot)	0,06	0,12	0,04	0,00	91 ms
Claude Haiku 5.5	0,42	0,64	0,32	0,44	1,5 s
GPT-6 Luna	0,48	0,58	0,37	0,27	1,7 s
DeepSeek V4.1 Flash	0,36	0,66	0,27	0,43	2,2 s
Qwen3.8 Flash	0,46	0,60	0,36	0,44	2,9 s
Qwen3.8 Max	0,50	0,70	0,38	5,24	3,7 s

Média dos três eixos. Custo calculado sobre os tokens medidos em cada chamada × preço de lista. XGBoost e Laya têm custo marginal zero.

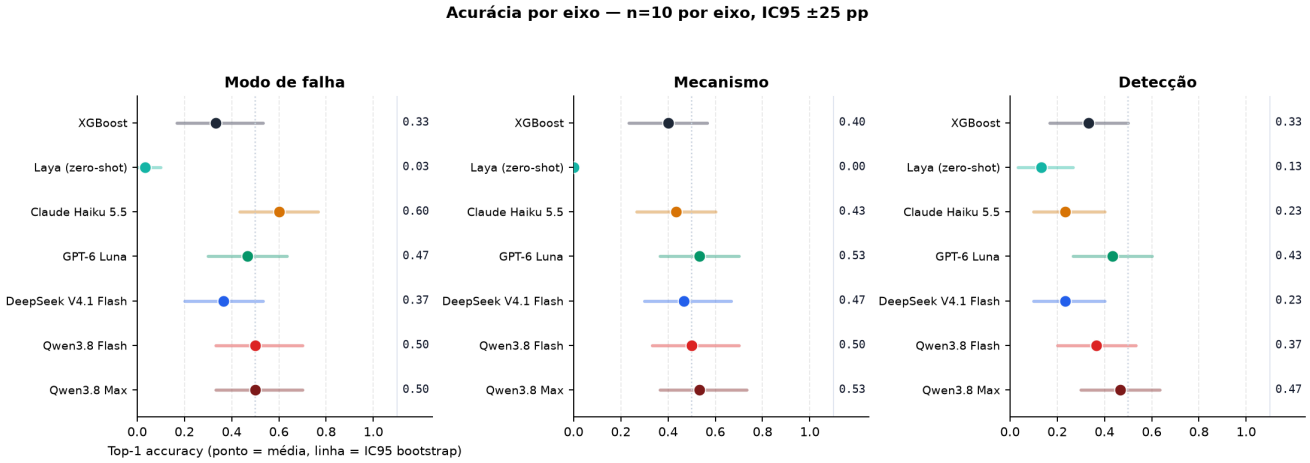


Figura 1 — Acurácia top-1 por eixo, com IC95 bootstrap. Com dez notas por eixo o intervalo é de cerca de 25 pontos percentuais: diferenças menores não sustentam ranking.

2.1 Por eixo

Modelo	Modo de falha	Mecanismo	Detecção
XGBoost	**0,33**	**0,40**	**0,33**
Laya (zero-shot)	0,03	0,00	0,13
Claude Haiku 5.5	0,60	0,43	0,23
GPT-6 Luna	0,47	0,53	0,43
DeepSeek V4.1 Flash	0,37	0,47	0,23
Qwen3.8 Flash	0,50	0,50	0,37
Qwen3.8 Max	0,50	0,53	0,47

Modo de falha é onde o Claude Haiku se destaca e o XGBoost fica para trás. **Mecanismo** é o mais equilibrado — todos entre 0,40 e 0,53. **Detecção** é o eixo mais fraco para quase todos: a nota diz *o que* falhou, não *como* alguém descobriu.

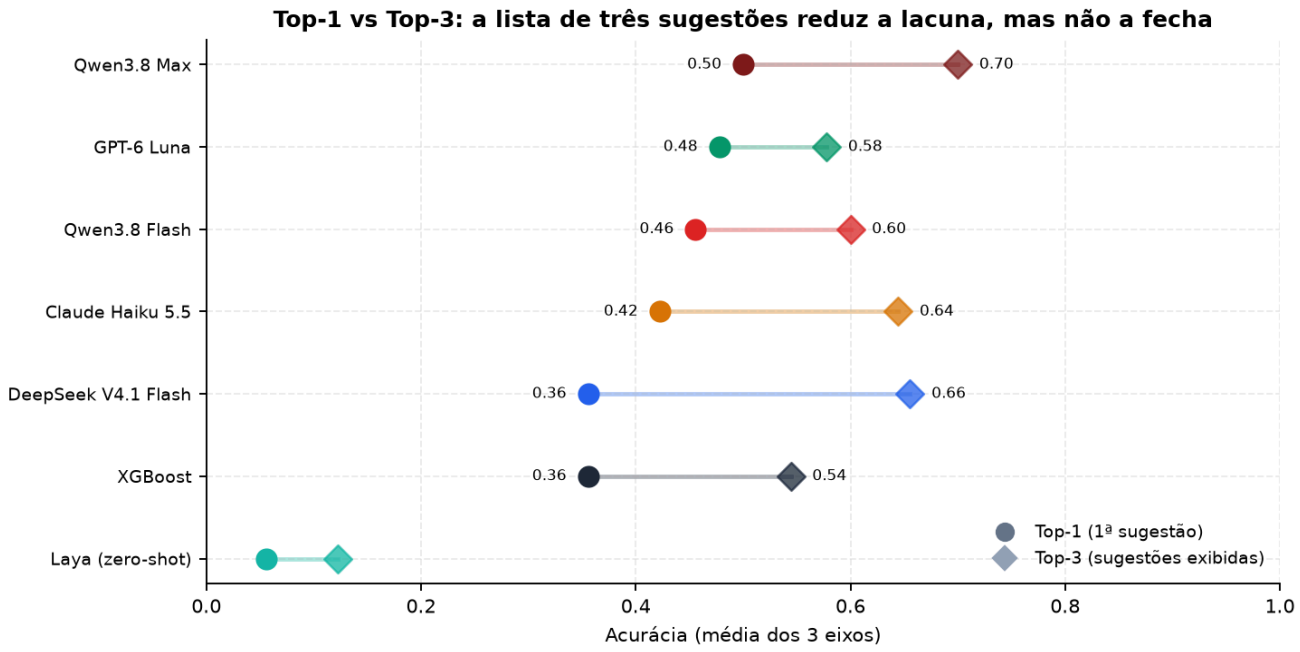


Figura 2 — Top-1 e top-3 do mesmo modelo. A lista de três reduz a distância entre os modelos, mas não a fecha.

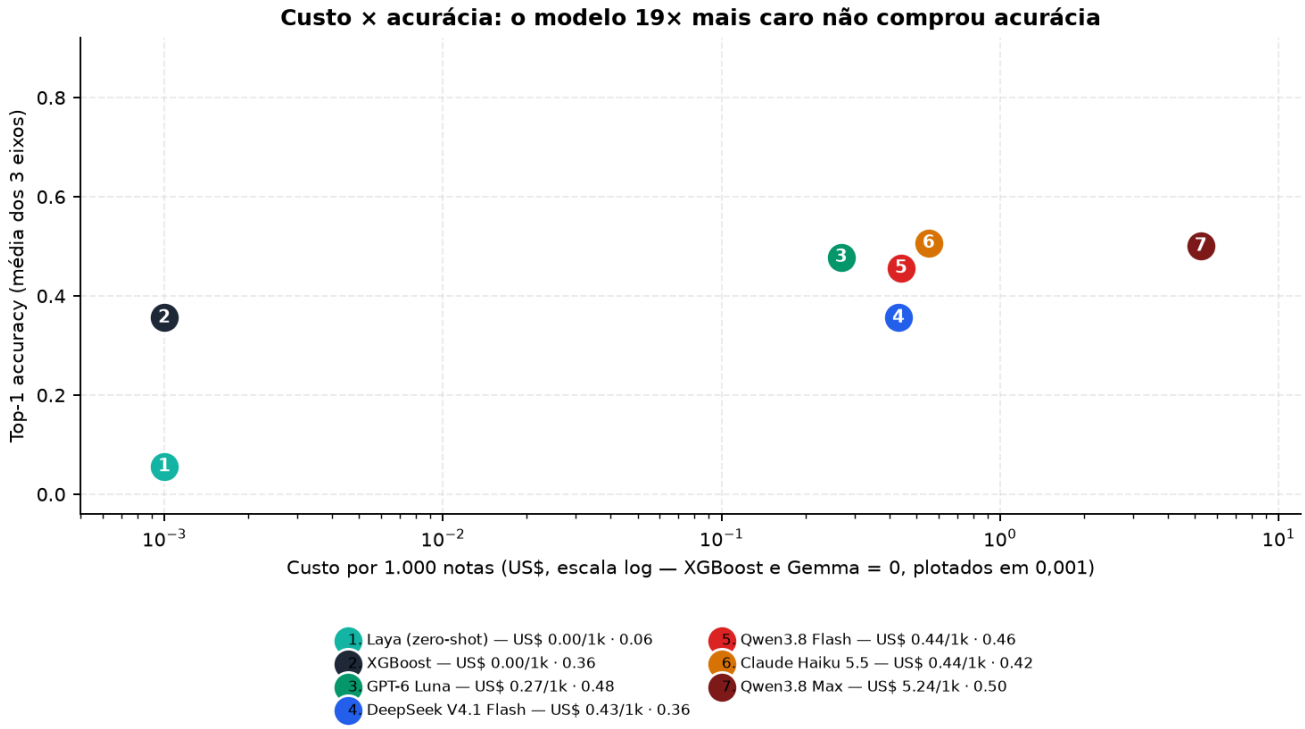


Figura 3 — Custo por mil notas × acurácia. O modelo 19× mais caro ganha dois pontos percentuais.

3. Custo e latência

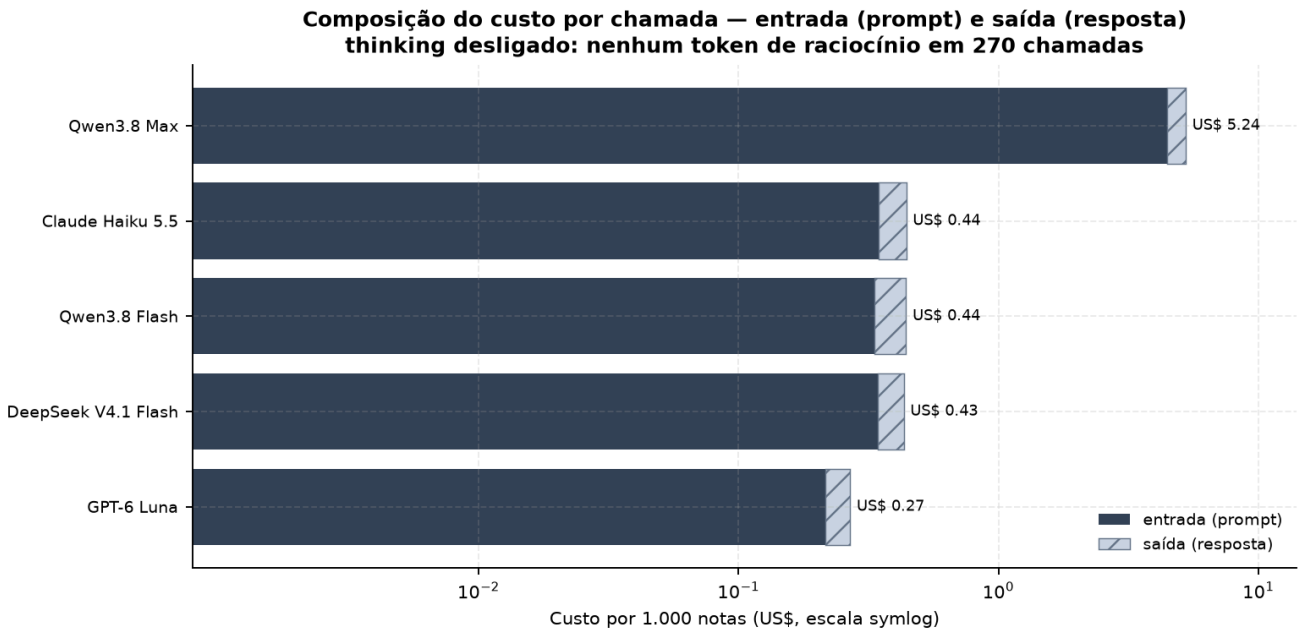


Figura 4 — Composição do custo por chamada: entrada (prompt) contra saída (resposta). O prompt domina a conta.

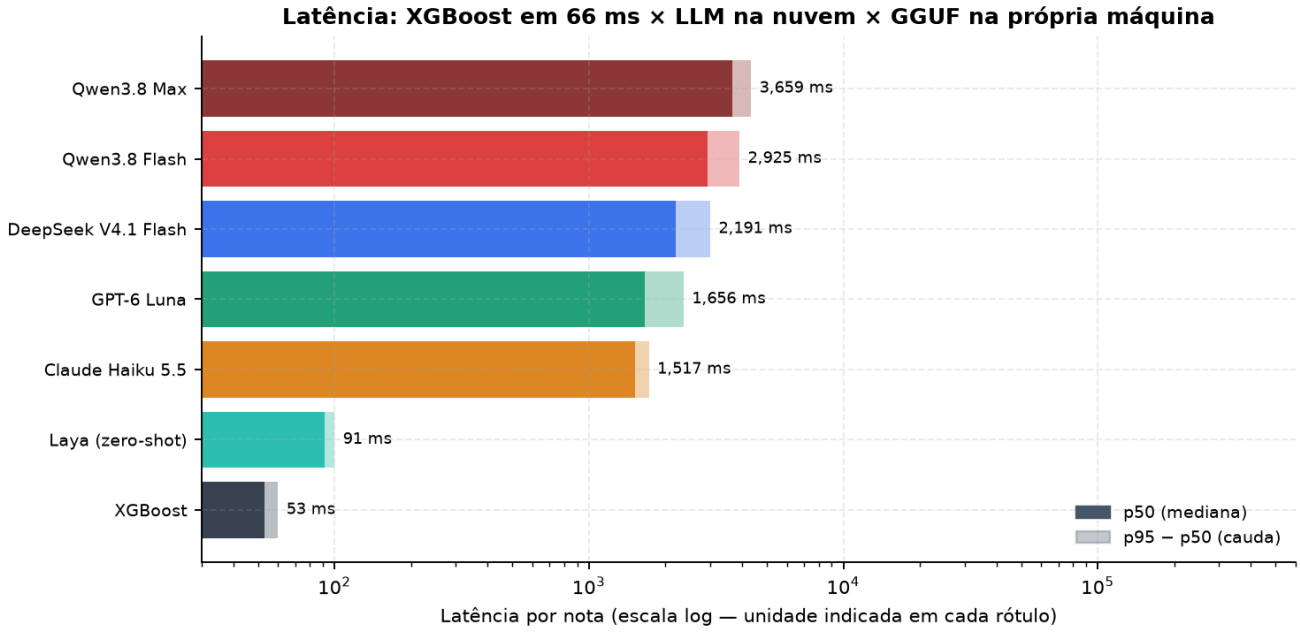


Figura 5 — Latência p50 por modelo, em escala logarítmica. O XGBoost responde em 53 ms; o LLM mais rápido, em 1,5 s.

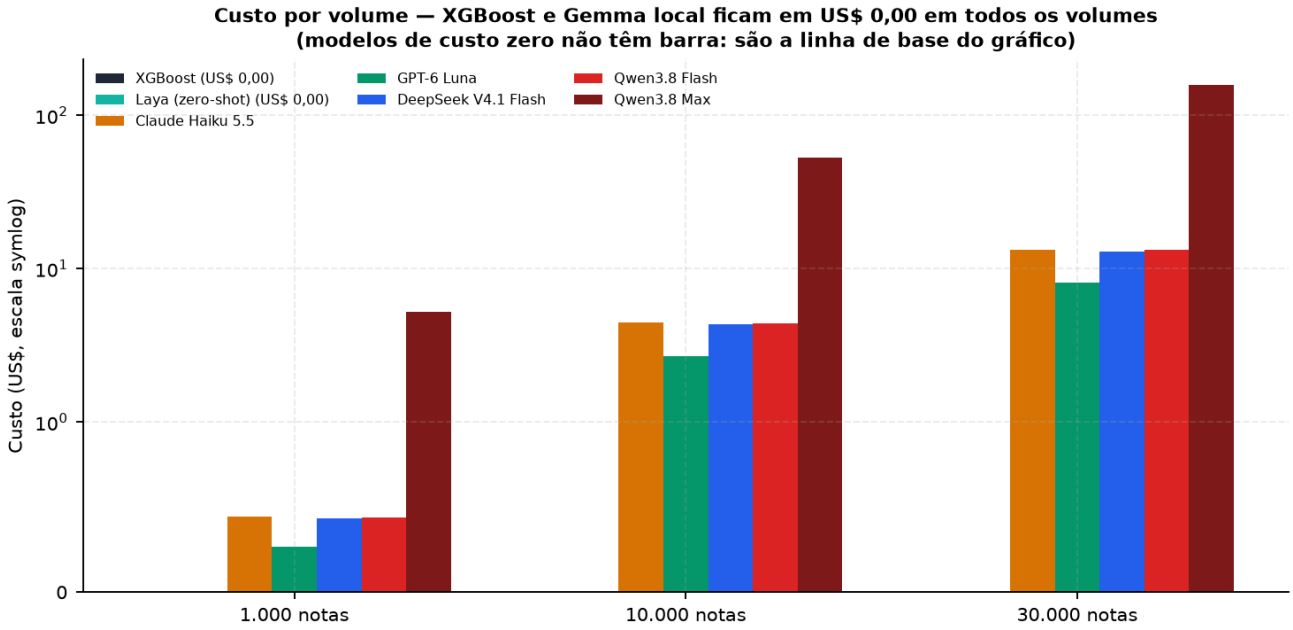


Figura 6 — Projeção de custo para 30 mil notas por mês. Modelos locais ficam em zero.

4. Melhoria de prompt: ISO 14224 e exemplos reais

Três variantes, mesmas 30 notas, cinco modelos de nuvem: taxonomia mínima (1.766 tokens), taxonomia + descrições da ISO 14224 (~3.400) e ISO + uma nota real por código (~9.100).

Modelo	Base top-1	Base top-3	+ISO top-1	+ISO top-3	+Exemplos top-1	+Exemplos top-3
Claude Haiku 5.5	0,42	0,64	0,37	0,64	0,34	0,61
GPT-6 Luna	0,48	0,58	0,42	0,53	0,44	0,59
DeepSeek V4.1 Flash	0,36	0,66	0,42	0,67	0,43	0,68
Qwen3.8 Flash	0,46	0,60	0,48	0,60	0,44	0,58
Qwen3.8 Max	0,50	0,70	0,44	0,69	0,47	0,72
Média	0,44	0,64	0,43	0,63	0,43	0,64

Mais contexto não melhorou a acurácia. A média caiu de 0,44 (prompt base) para 0,43 com a ISO e ficou em 0,43 com os exemplos. No top-3 também não há ganho: 0,64 → 0,63 → 0,64. O custo, esse subiu: **1,7×** com a ISO e **3,2×** com os exemplos.

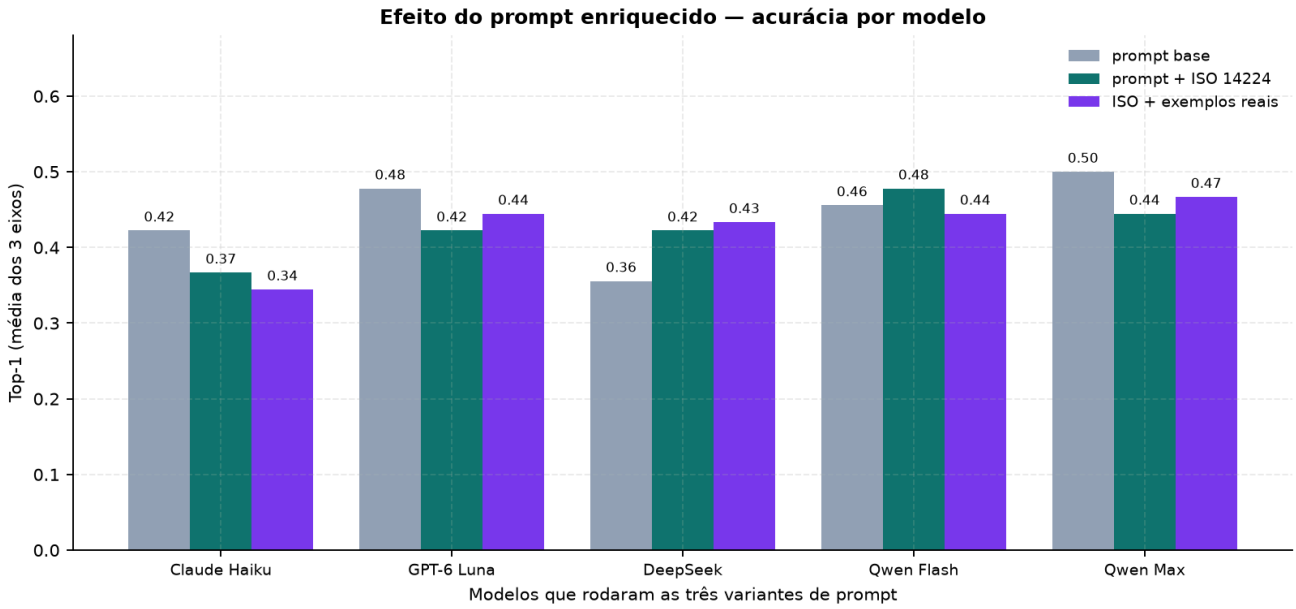


Figura 7 — Efeito do prompt enriquecido por modelo. Nenhum ganho consistente.

5. Exemplos reais

Doze notas entre as 30 — dois acertos e dois erros do XGBoost por eixo — com o gabarito do especialista e a primeira sugestão de cada modelo.

Exemplos do eixo modo de falha

NOTA 1636 · tag **alarme_temperatura_mancal_09** · impacto U

"Alarme de temperatura alta ativado sem aquecimento real. A análise indica erro de configuração no setpoint, resultando em alarme espúrio."

Gabarito do especialista: `SHH` Alarme alto espúrio

Modelo	Sugestão	Acerto
XGBoost	`SHH`	✓
Laya (zero-shot)	`ALR`	✗
Claude Haiku 5.5	`SHH`	✓
GPT-6 Luna	`SHH`	✓
DeepSeek V4.1 Flash	`SHH`	✓
Qwen3.8 Flash	`SHH`	✓
Qwen3.8 Max	`SHH`	✓

NOTA 2172 · tag **piso_fabrica_buraco_02** · impacto U

"Buraco no piso industrial. A análise indica tráfego pesado e concreto de baixa resistência."

Gabarito do especialista: `STD` Def. estrutural

Modelo	Sugestão	Acerto
XGBoost	`STD`	✓
Laya (zero-shot)	`021`	✗
Claude Haiku 5.5	`STD`	✓
GPT-6 Luna	`STD`	✓
DeepSeek V4.1 Flash	`STD`	✓
Qwen3.8 Flash	`STD`	✓
Qwen3.8 Max	`STD`	✓

NOTA 0443 · tag **secador_rotativo_35** · impacto S

“Secador rotativo no momento de partida apresentou perda significativa de desempenho. A análise preliminar indica danos térmicos devido à sobrecarga, resultando em redução de eficiência operacional.”

Gabarito do especialista: `OHE` Superaquecimento

Modelo	Sugestão	Acerto
XGBoost	`LOP`	✗
Laya (zero-shot)	`SER`	✗
Claude Haiku 5.5	`OHE`	✓
GPT-6 Luna	`LOO`	✗
DeepSeek V4.1 Flash	`IHT`	✗
Qwen3.8 Flash	`FTI`	✗
Qwen3.8 Max	`AOL`	✗

NOTA 1008 · tag **tanque_de_armazenamento_27** · impacto U

“Tanque de armazenamento durante teste funcional parou repentinamente sem alarme prévio. A análise preliminar indica obstrução parcial interna, resultando em interrupção inesperada na produção.”

Gabarito do especialista: `PLU` Entupido

Modelo	Sugestão	Acerto
XGBoost	`FTS`	✗
Laya (zero-shot)	`CSF`	✗
Claude Haiku 5.5	`PLU`	✓
GPT-6 Luna	`PLU`	✓
DeepSeek V4.1 Flash	`PLU`	✓
Qwen3.8 Flash	`PLU`	✓
Qwen3.8 Max	`PLU`	✓

Exemplos do eixo mecanismo

NOTA 3154 · tag **sensor_nivel_espuma** · impacto S

“Sensor de nível ultrassônico indicando nível baixo falso. Camada densa de espuma absorveu o sinal do sensor.”

Gabarito do especialista: `5.3` Influência externa

Modelo	Sugestão	Acerto
XGBoost	`5.3`	✓
Laya (zero-shot)	`2.9`	✗
Claude Haiku 5.5	`3.3`	✗
GPT-6 Luna	`5.3`	✓
DeepSeek V4.1 Flash	`5.2`	✗
Qwen3.8 Flash	`3.3`	✗
Qwen3.8 Max	`5.3`	✓

NOTA 3746 · tag **valvula_diafragma_travada_vacuo** · impacto S

“Válvula de diafragma não abre. O diafragma "colou" na sede devido ao vácuo na linha quando parada.”

Gabarito do especialista: `5.9` Fora pressão/temp

Modelo	Sugestão	Acerto
XGBoost	`5.9`	✓
Laya (zero-shot)	`1.6`	✗
Claude Haiku 5.5	`1.6`	✗
GPT-6 Luna	`1.6`	✗
DeepSeek V4.1 Flash	`1.6`	✗
Qwen3.8 Flash	`1.6`	✗
Qwen3.8 Max	`1.6`	✗

NOTA 0214 · tag **válvula_de_controle_72** · impacto U

“Válvula de controle após parada programada apresentou vibração excessiva com aumento progressivo. A análise preliminar indica fadiga mecânica por ciclos elevados, resultando em necessidade de intervenção imediata.”

Gabarito do especialista: `2.6` Fadiga

Modelo	Sugestão	Acerto
XGBoost	`4.4`	✗
Laya (zero-shot)	`1.7`	✗
Claude Haiku 5.5	`2.6`	✓
GPT-6 Luna	`2.6`	✓
DeepSeek V4.1 Flash	`2.6`	✓
Qwen3.8 Flash	`2.6`	✓
Qwen3.8 Max	`2.6`	✓

NOTA 1993 · tag **quebra_peca_nova** · impacto D

“Eixo novo quebrou prematuramente. A análise metalográfica inconclusiva sobre fadiga ou defeito de material.”

Gabarito do especialista: `2.6` Fadiga

Modelo	Sugestão	Acerto
XGBoost	`6.4`	✗
Laya (zero-shot)	`1.8`	✗
Claude Haiku 5.5	`2.6`	✓
GPT-6 Luna	`2.5`	✗
DeepSeek V4.1 Flash	`2.5`	✗
Qwen3.8 Flash	`2.10`	✗
Qwen3.8 Max	`2.5`	✗

Exemplos do eixo detecção

NOTA 3995 · tag **secador_rotativo_vibracao** · impacto S

“Secador vibrando. Rolos de apoio desalinhados ou ovais.”

Gabarito do especialista: 5 Monitor. contínuo

Modelo	Sugestão	Acerto
XGBoost	5	✓
Laya (zero-shot)	2	✗
Claude Haiku 5.5	7	✗
GPT-6 Luna	7	✗
DeepSeek V4.1 Flash	7	✗
Qwen3.8 Flash	4	✗
Qwen3.8 Max	7	✗

NOTA 4314 · tag **painel_contator_corretiva_03** · impacto U

“Ao trocar o contator queimado, viu-se que o trilho DIN estava solto. Falha de fixação encontrada na corretiva elétrica.”

Gabarito do especialista: 8 Manut. corretiva

Modelo	Sugestão	Acerto
XGBoost	8	✓
Laya (zero-shot)	8	✓
Claude Haiku 5.5	8	✓
GPT-6 Luna	8	✓
DeepSeek V4.1 Flash	8	✓
Qwen3.8 Flash	8	✓
Qwen3.8 Max	8	✓

NOTA 0383 · tag **forno_industrial_85** · impacto D

“Forno industrial durante operação contínua entregou leituras inconsistentes nos instrumentos. A análise preliminar indica trinca evolutiva não detectada anteriormente, resultando em aumento do consumo de energia.”

Gabarito do especialista: 4 Monitor. periódico

Modelo	Sugestão	Acerto
XGBoost	7	✗
Laya (zero-shot)	5	✗
Claude Haiku 5.5	8	✗
GPT-6 Luna	7	✗
DeepSeek V4.1 Flash	5	✗
Qwen3.8 Flash	6	✗
Qwen3.8 Max	5	✗

NOTA 1999 · tag **termostato_descalibrado** · impacto S

“Termostato atuando antes da temperatura. A análise indica perda de calibração, resultando em alarme de alta temperatura prematuro.”

Gabarito do especialista: 9 Sob demanda

Modelo	Sugestão	Acerto
XGBoost	2	✗
Laya (zero-shot)	3	✗
Claude Haiku 5.5	8	✗
GPT-6 Luna	7	✗
DeepSeek V4.1 Flash	5	✗
Qwen3.8 Flash	5	✗
Qwen3.8 Max	5	✗

6. Determinismo e acerto por nota

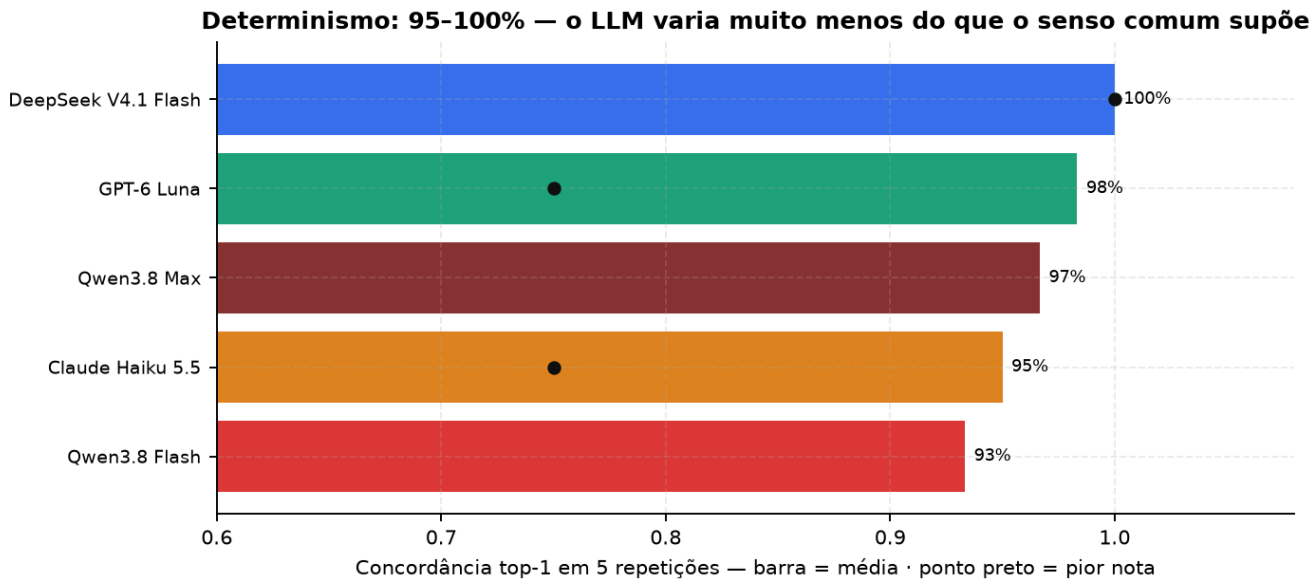


Figura 8 — Concordância top-1 em cinco repetições da mesma nota. A barra é a média; o ponto preto, a pior nota.

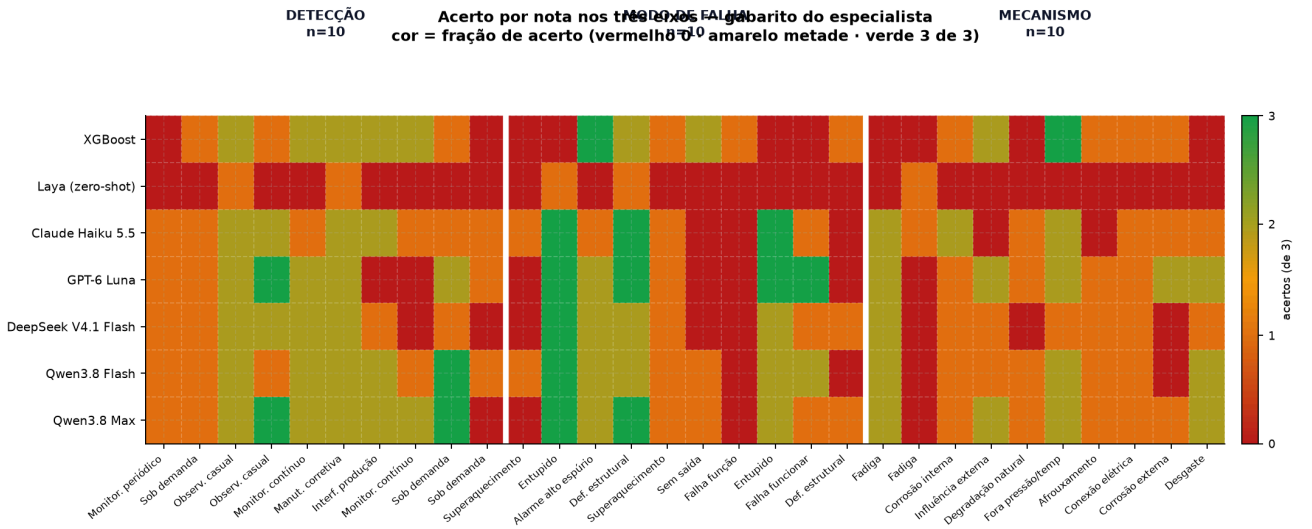


Figura 9 — Acerto por nota nos três eixos, contra o gabarito do especialista. Verde = três acertos; vermelho = nenhum.

7. Conclusão

> **Contra o gabarito validado, o LLM ganha — e o preço decide qual.** O Qwen3.8 Max faz 0,50 de top-1 e 0,70 de top-3 a US$ 5,24 por mil notas; o GPT-6 Luna faz 0,48 e 0,58 a US$ 0,27; o XGBoost faz 0,36 e 0,54 a custo zero e em 53 ms.

O classificador não perdeu por arquitetura: perdeu porque aprendeu o molde do corpus. As notas seguem o formato "X apresentou *sintoma*. A análise indica *causa*, resultando em *consequência*", e o TF-IDF decora essa estrutura — quando a nota foge do molde, ele não generaliza. Já o LLM lê a frase como um engenheiro leria.

O que fica claro é que a pergunta "qual modelo é melhor" depende do gabarito. Sem a validação do especialista, estaríamos comparando modelos contra um rótulo que não se sustenta — e premiando quem decorou o rótulo.

8. Limitações e próximos passos

- **Amostra modesta.** Dez notas por eixo dão IC95 de ±25 pontos percentuais: diferenças menores não sustentam ranking.
- **Um único anotador.** 90 respostas de uma pessoa; sem dupla anotação não há Kappa.
- **Corpus template.** As notas seguem moldes e muitas enunciam o mecanismo no texto, o que favorece qualquer modelo que leia a frase.
- **XGBoost in-sample.** O modelo da tabela viu as 30 notas; fora da amostra, 0,33.
- **Próximos passos:** dupla anotação com Kappa, n=100 por eixo (IC95 ±7,8 pp), re-treinar o XGBoost sem a coluna de tag e avaliar em notas de campo, escritas por técnicos.

Apêndice — Prompt usado

```
SYSTEM
Voce e um engenheiro de confiabilidade especialista na taxonomia ISO 14224.
Classifique a nota de manutencao em tres eixos, escolhendo APENAS codigos das listas fornecidas.
Responda exclusivamente com JSON valido, sem markdown e sem texto fora do JSON, no formato:
{"modo":[{"codigo":"XXX","confianca":0.00}],
 "mecanismo":[{"codigo":"X.X","confianca":0.00}],
 "deteccao":[{"codigo":"X","confianca":0.00}]}
Ordene do mais provavel para o menos provavel, no maximo 3 itens por eixo.
Nao invente codigos: cada codigo precisa existir na lista do eixo correspondente.

USER
NOTA DE MANUTENCAO
Tag: {tag}
Impacto: {impacto}  (D=critica/parada, S=degradada, U=incipiente, X=outros)
Descricao: {descricao}

TAXONOMIA - MODO DE FALHA (FailMode)
{codigo} | {descricao}
... (62 codigos)

TAXONOMIA - MECANISMO (FailMech)
... (64 codigos)

TAXONOMIA - METODO DE DETECCAO (DetMethod)
... (10 codigos)
```